

Analyse factorielle d'un nuage de points

GHAZI BEL MUFTI

ghazi.belmufti@gmail.com

ESSAI-1 / ANALYSE DES DONNÉES

Plan

1. Tableau de données ; notations
2. Nuages des individus et nuages des variables
3. Caractéristiques d'un nuage de points
4. Résultat d'une analyse factorielle

Rappels d'algèbre linéaire : espace euclidien, produit scalaire

Soit E un espace vectoriel (e. v.) sur \mathbb{R} de dimension n . Si f est une application de $\mathbb{E} \times \mathbb{E}$ dans \mathbb{R} , on dit que :

- (1) f est bilinéaire si f est linéaire par rapport à chaque composante
- (2) f est symétrique si pour tout x, y de \mathbb{E} , $f(x, y) = f(y, x)$
- (3) f est définie si pour tout x de \mathbb{E} , $f(x, x) = 0 \Leftrightarrow x = 0$
- (4) f est positive si pour tout x de \mathbb{E} , $f(x, x) \geq 0$

Si f vérifie les conditions (1) à (4), on dit que f est une forme bilinéaire symétrique définie positive ou encore que f est un **produit scalaire**. Dans ce cas, la forme f est associée à :

- une forme quadratique $q : q(x) = f(x, x)$
- une norme euclidienne $|| \cdot || : ||x|| = \sqrt{f(x, x)}$
- une distance euclidienne $d : d(x, y) = ||x - y||$
- une orthogonalité $\perp_f : x$ est f-orthogonal à $y \Leftrightarrow f(x, y) = 0$

- On appelle **espace euclidien** tout espace vectoriel muni d'un produit scalaire.
- Si f est un produit scalaire défini sur \mathbb{E} que l'on munit de la base $\{e_i\}_{1 \leq i \leq n}$, alors la matrice M de terme général $f(e_i, e_j)$ pour i et j variant de 1 à n (c'est-à-dire $M = (f(e_i, e_j))_{1 \leq i, j \leq n}$) vérifie :

$$\forall x, y \in \mathbb{E} \quad f(x, y) = x' M y$$

- On dit alors que M est la matrice associée au produit scalaire f .
- On en déduit :

$$d^2(x, y) = \|x - y\|^2 = q(x - y) = (x - y)' M (x - y)$$

$$x \text{ est } M\text{-orthogonal à } y \Leftrightarrow x' M y = 0$$

- Lorsque l'on ne précise pas le produit scalaire utilisé, c'est qu'il s'agit du produit scalaire "usuel", c'est-à-dire du produit scalaire, noté \langle, \rangle défini par :

$$\langle x, y \rangle = \sum_{i=1}^n x_i y_i = x' y = x' I y$$

- Le produit scalaire usuel a donc pour matrice associée la matrice identité I . Ainsi, un système $\{x_i\}_{1 \leq i \leq r}$ sera dit orthonormé si les vecteurs x_i sont normés et orthogonaux deux à deux pour le produit scalaire usuel, c'est-à-dire si :

$$\forall i, j, \langle x_i, x_j \rangle = x_i' x_j = \delta_{ij}$$

Remarques

1. Un système $\{x_i\}_{1 \leq i \leq r}$ est orthonormé si la matrice X dont les vecteurs colonnes sont les x_i , c'est-à-dire si la matrice $X = (x_1, \dots, x_r)$, est orthogonale, autrement dit si :

$$X'X = I \text{ ou } X^{-1} = X'$$

2. Notation : étant donné un produit scalaire f quelconque, on peut écrire

$$f(x, y) = x' M y = y' M x = \langle Mx, y \rangle = \langle x, My \rangle = \langle x, y \rangle_M$$

Par la suite, M pourra aussi bien désigner le produit scalaire f ou sa forme quadratique associée, ou simplement la matrice M qui sera appelée **métrique** (sur \mathbb{E}).

1. Tableau de données ; notations

On note $I = \llbracket 1, n \rrbracket$ et $J = \llbracket 1, p \rrbracket$ qui sont les ensembles d'indices désignant respectivement les n individus et les p variables.

$$X = (x_i^j)_{i \in I, j \in J} \in \mathcal{M}_{n,p}(\mathbb{R})$$

Ainsi les valeurs prises par la variable x^j pour les n individus se lisent sur la $j^{\text{ème}}$ colonne et les valeurs prises par l'individu i pour les p variables se lisent sur la $i^{\text{ème}}$ ligne de X .

$$\forall (i, j) \in I \times J, x_i = \begin{pmatrix} x_i^1 \\ \vdots \\ x_i^p \end{pmatrix} \in \mathbb{R}^p \quad x^j = \begin{pmatrix} x_1^j \\ \vdots \\ x_n^j \end{pmatrix} \in \mathbb{R}^n$$

2. Nuages des individus et nuages des variables

A la matrice X , on associe deux nuages de points : celui des individus et celui des variables.

$$\mathcal{M}_X = \{x_1, \dots, x_n\} \subseteq \mathbb{R}^p \quad \text{nuage des individus}$$

$$\mathcal{N}_X = \{x^1, \dots, x^p\} \subseteq \mathbb{R}^n \quad \text{nuage des variables}$$

- Le nuage \mathcal{M}_X est muni de la métrique M de \mathbb{R}^p , et chaque individu i est muni d'une masse p_i telle que $\sum_i p_i = 1$ (souvent $p_i = \frac{1}{n}$).
- Le nuage \mathcal{N}_X est muni de la métrique D_p de \mathbb{R}^n avec

$$D_p = \text{Diag}(p_i)_{1 \leq i \leq n}.$$

3. Caractéristiques d'un nuage de points

3.1 Centre de gravité. Le centre de gravité du nuage des individus affecté des poids p_i est le point g centre de gravité de \mathcal{M}_X :

$$g = \sum_{i=1}^n p_i x_i$$

La $j^{\text{ème}}$ coordonnée de g est donnée par : $g_j = \sum_{i=1}^n p_i x_i^j = \overline{x^j}$.

Ainsi g_j est la moyenne de la variable x^j et les coordonnées de g sont les moyennes des p variables.

Remarque : On vérifie facilement que $g = X' D_p 1_n$ où 1_n est le vecteur de \mathbb{R}^n dont toutes les coordonnées sont égales à 1.

3.2 Matrice centrée. On centre toujours le nuage des individus sur le centre de gravité g , c'est-à-dire, on construit un nouveau tableau Y tel que

$$\forall (i, j) \in I \times J, y_i^j = x_i^j - \overline{x^j}$$

soit

$$\forall i \in I, y_i = x_i - g$$

3.3 Matrice Variance. Par définition, la matrice variance V , des p variables pour les n individus est une matrice carrée d'ordre p et de terme général $v_{j,j'}$ donnée par :

$$\forall (j, j') \in \llbracket 1, p \rrbracket, v_{j,j'} = \text{cov}(x^j, x^{j'}) = \sum_{i=1}^n p_i (x_i^j - g_j)(x_i^{j'} - g_{j'}) = \langle y^j, y^{j'} \rangle_{D_p}.$$

En notations matricielles, on a :

$$V = Y' D_p Y = X' D_p X - g g'$$

3.4 Le tableau centré réduit. En divisant chaque variable par son écart-type, on obtient un nouveau tableau Z dont les variables sont toutes centrées réduites. On a :

$$\forall (i, j) \in I \times J, z_i^j = \frac{x_i^j - \bar{x}^j}{\sqrt{v_{jj}}}$$

D'où $Z = Y\Delta$ où $\Delta = \text{diag}(\frac{1}{\sqrt{v_{11}}}, \dots, \frac{1}{\sqrt{v_{pp}}})$.

3.5 Matrice de corrélation. La matrice $Z' D_p Z$ est la matrice de corrélation. Donc $R = V_Z$, où V_Z désigne la matrice variance associée au tableau Z . On a :

$$R = \Delta V \Delta$$

4. Résultat d'une analyse factorielle

- L'analyse factorielle d'un tableau X a pour but de trouver un sous-espace E_k , de dimension k , tel que l'inertie totale de la projection de \mathcal{M}_Y sur E_k soit maximale.
- On montre que les sous-espaces E_α solution de ce problème sont emboîtés lorsque k varie.

$$E_1 \subset E_2 \dots \subset E_p = E$$

- La droite E_1 est générée par un vecteur normé u_1 . Le plan E_2 est générée par le couple (u_1, u_2) où u_2 est normé et orthogonal à u_1 . Donc $E_1 \subset E_2$. Le sous-espace E_k est généré par (u_1, \dots, u_k) où u_k normé est orthogonal à E_{k-1} généré par (u_1, \dots, u_{k-1}) .
- Le vecteur u_k ($1 \leq k \leq p$) s'appelle le k ème **vecteur axial factoriel** et la droite dirigée par u_k , notée Δu_k , est appelée $k^{\text{ème}}$ axe factoriel.
- Les vecteurs u_k ($1 \leq k \leq p$) forment un système orthonormé de E : l'analyse factorielle revient à un changement de base.

4.1 Axes factoriels u_α ($1 \leq \alpha \leq p$). u_α est solution de l'équation aux valeurs propres et vecteurs propres :

$$\begin{cases} VM u_\alpha = \lambda_\alpha u_\alpha \\ (u_\alpha)' M u_\beta = \delta_\alpha^\beta \end{cases}$$

avec $\delta_\alpha^\beta = 0$ si $\alpha \neq \beta$ et 1 sinon

L'inertie de la projection de \mathcal{M}_Y sur Δu_α vaut λ_α .

4.2 Les composantes principales ψ_α ($1 \leq \alpha \leq p$). Par définition

$$\psi_\alpha = \begin{pmatrix} \psi_{1,\alpha} \\ \vdots \\ \psi_{n,\alpha} \end{pmatrix} = Y M u_\alpha$$

est appelée $\alpha^{\text{ème}}$ **composante principale**. On a :

$$\psi_{i,\alpha} = (y_i)' M u_\alpha$$

D'autre part, on a :

$$VM u_\alpha = Y' D_p Y M u_\alpha = Y' D_p \psi_\alpha = \lambda_\alpha u_\alpha$$

D'où, en multipliant par YM à gauche :

$$YMY'D_p\Psi_\alpha = \lambda_\alpha YMu_\alpha = \lambda_\alpha \Psi_\alpha$$

Autrement dit, en posant $W = YMY'$, le vecteur Ψ_α est vecteur propre de WD_p relatif à la valeur propre λ_α . Les Ψ_α sont donc solution de :

$$\begin{cases} WD_p\Psi_\alpha = \lambda_\alpha \Psi_\alpha \\ (\Psi_\alpha)'D_p\Psi_\beta = \lambda_\alpha \delta_\alpha^\beta \end{cases}$$

En effet :

$$\begin{aligned} \langle \Psi_\alpha, \Psi_\beta \rangle_{D_p} &= \Psi_\alpha' D_p \Psi_\beta \\ &= u_\alpha' MY' D_p YMu_\beta \\ &= u_\alpha' MVMu_\beta \\ &= \lambda_\beta \langle u_\alpha, u_\beta \rangle_M \end{aligned}$$

4.3 Inertie

- Soit $I_T = \text{trace}(VM)$ l'inertie totale du nuage. Le taux d'inertie expliqué par le $\alpha^{\text{ème}}$ axe factoriel, noté τ_α est la quantité

$$\tau_\alpha = \frac{\lambda_\alpha}{I_T} = \frac{\lambda_\alpha}{\sum_{i=1}^p \lambda_i}$$

- Le taux d'inertie expliqué par E_α , noté $\tau_{1\dots\alpha}$ est la quantité

$$\tau_{1\dots\alpha} = \frac{\lambda_1 + \dots + \lambda_\alpha}{I_T} = \sum_{i=1}^{\alpha} \tau_i$$

4.4 Représentation des variables

- On suppose la matrice V de rang r . Comme V et VM ont même rang (M étant inversible), les valeurs propres $\lambda_{r+1}, \dots, \lambda_p$ sont nulles.
- Un individu i a $p - r$ coordonnées nulles donc est caractérisé par r valeurs $\psi_{i,1}, \dots, \psi_{i,r}$ au lieu des p coordonnées initiales.

E.V. engendré par les variables.

On a vu que :

$$\forall (\alpha, \beta) \in \llbracket 1, p \rrbracket^2, \langle \psi_\alpha, \psi_\beta \rangle_{D_p} = \begin{cases} \lambda_\alpha & \text{si } \alpha = \beta \\ 0 & \text{si } \alpha \neq \beta \end{cases}$$

En posant :

$$\forall \alpha \in \llbracket 1, r \rrbracket, v_\alpha = \frac{\psi_\alpha}{\sqrt{\lambda_\alpha}},$$

On en déduit que :

(v_1, \dots, v_r) est une base D_p -orthonormale de $\text{Vect}(y^1, \dots, y^p) = \text{Im} Y$

Coordonnées des variables.

On se place dans la base (v_1, \dots, v_r) pour représenter les variables.
La α ème coordonnée de la variable centrée y^j est donnée par :

$$\eta_j^\alpha = \langle y^j, \frac{\psi_\alpha}{\sqrt{\lambda_\alpha}} \rangle_{D_p}.$$

On a :

$$\eta^\alpha = \begin{pmatrix} \eta_1^\alpha \\ \vdots \\ \eta_p^\alpha \end{pmatrix} = \sqrt{\lambda_\alpha} u_\alpha$$